

**Exploration des
données**

Open Food Facts

pour

Santé publique France



Sommaire

- L'appel à projets
- Le jeu de données
- Cadre de l'étude
- Nettoyage des données
- Analyse exploratoire
- Conclusion



L'appel à projets

- Santé publique France
- Open Food Fact
- Données accessibles



L'appel à projets



Le jeu de données

- Dimensionnalité
- Types
- Contenu
- Valeur manquantes



Le jeu de données - le fichier

- 320772 lignes : Produits alimentaires
- 162 colonnes : Informations relatives aux produit
 - 106 colonnes quantitatives
 - 56 colonnes qualitatives.

Le jeu de données - informations

- Informations générales (produit, créateur, date...)
- Etiquettes (origine, catégorie...)
- Ingrédients
- Divers (additifs...)
- Apports nutritionnels

Le jeu de données - valeurs manquantes

Le cadre de l'étude


- Objectif / cadre
- Valeurs manquantes
- Filtrage
- Indicateurs



Le cadre de l'étude - objectif



Le cadre de l'étude - valeurs manquantes




Le cadre de l'étude - produits vendus en France

```
2998
France
4392
Suisse
4953
Allemagne
7870
Espagne
5009

...
Belgique, France, Allemagne, Italie, Maroc, Portugal, Serbie, Suisse
1
Géorgie
1
Belgique, Brésil, Canada, France, Suisse
```

Groupes de pays



Après filtrage

98440 produits sont des produits vendus en France

6 colonnes ont plus de 90% de valeurs manquantes.

Le cadre de l'étude - indicateurs

Quantitatifs

Colonnes terminant par "_100g"
Informations nutritionnelles pour 100 grammes.


Nutriments, Energie, Nutriscore

Qualitatifs

product_name
nutrition_grade_fr (grade de 'a' à 'e')

Produit, nutrigrade

→ 12 colonnes



Nutriscore : FR et UK

Nettoyage des données

- Valeurs manquantes
- Doublons
- Valeurs aberrantes
- Valeurs atypiques
- Imputation des valeurs manquantes



Nettoyage - valeurs manquantes

% de valeurs manquantes	
fiber_100g	53.552418
carbohydrates_100g	52.040837
fat_100g	51.603007
nutrition-score-fr_100g	37.611743
nutrition_grade_fr	37.611743
saturated-fat_100g	36.636530
sugars_100g	36.494311
sodium_100g	36.437424
salt_100g	36.434376
proteins_100g	34.662739
energy_100g	34.383381
product_name	7.306989

7193 lignes sans nom de produit

30175 produits sans nutrition score / grade

37368 lignes supprimées

Nettoyage - doublons

892 lignes complètes sont des doublons

Doublons des noms de produit :

	nutrition_grade_fr	product_name	energy_100g	fat_100g	saturated-fat_100g	cholesterol_100g	alt_100g	sodium_100g	nutrition-score-fr_100g	clean_product_name
210617	a	Vermicelles de riz	809.0	0.5	0.0	0.0	0.0000	0.000000	-1.0	vermicelles
211555	b	Vermicelles De Riz	1490.0	NaN	0.0	0.0	0.0300	0.011811	2.0	vermicelles
249167	c	Vermicelles De Riz	1481.0	NaN	0.0	0.0	0.1000	0.039370	4.0	vermicelles
257226	a	Vermicelles de riz	1536.0	1.0	0.3	0.0	0.0000	0.000000	-3.0	vermicelles
268503	a	Vermicelles de riz	1460.0	1.0	1.0	0.0	0.0450	0.017717	-1.0	vermicelles
317010	a	Vermicelles de riz brun	1510.0	3.0	0.8	0.0	0.0000	0.000000	-5.0	vermicellesderiz
317611	b	Vermicelles de Riz (Bun Gao)	1393.0	0.2	0.0	0.0	0.1016	0.040000	1.0	vermicellesderizbu
317665	d	Vermicelles de Riz	1389.0	NaN	0.0	0.0	0.8000	0.314961	17.0	vermicelles
317682	b	Vermicelles de riz	355.0	0.0	0.0	0.0	0.0000	0.000000	1.0	vermicelles
320577	b	Vermicelles de riz thai	1504.0	0.4	0.2	0.0	0.0100	0.003937	0.0	vermicellesderi

Nettoyage - doublons

		duplicates products lines	duplicates products names	data len	data len without duplicates products
0	without product name cleaning	13007	3960	60180	51133
1	with product name cleaning	18940	5172	60180	46412

14660 lignes ont été supprimées lors de la suppression des doublons.

Nettoyage - valeurs aberrantes

	energy_100g	fat_100g	saturated-fat_100g	carbohydrates_100g	sugars_100g	fiber_100g	proteins_100g	salt_100g	sodium_100g
count	46346.000000	32162.000000	46346.000000	32120.000000	46346.000000	34463.000000	46346.000000	46346.000000	46346.000000
mean	1132.882752	13.045300	5.475904	28.746531	13.740376	2.572091	7.784416	1.083481	0.4265
std	1147.794382	15.716449	8.416308	27.208711	18.955861	4.766658	7.846391	3.912266	1.5402
min	0.000000	0.000000	0.000000	0.000000	-0.100000	0.000000	0.000000	0.000000	0.0000
25%	451.250000	1.600000	0.370000	4.700000	1.100000	0.000000	2.100000	0.080010	0.0315
50%	1046.000000	7.330000	2.000000	16.500000	4.400000	1.330000	6.000000	0.540000	0.2125
75%	1669.000000	21.000000	7.500000	54.000000	19.600000	3.200000	10.800000	1.200000	0.4724
max	182764.000000	380.000000	210.000000	190.000000	104.000000	178.000000	100.000000	211.000000	83.0000


Des valeurs supérieures à 100

Des valeurs négatives

Densité massique (lipides) : 37 KJ/g soit 3700 KJ/100g.

Nettoyage - valeurs atypiques

Nutriments (grammes)



Nettoyage - valeurs atypiques

Bornes 1,5*interquartiles


	Colonne	Bornes
0	fat_100g	[-26.5, 49.5]
1	saturated-fat_100g	[-12.0, 20.0]
2	carbohydrates_100g	[-68.5, 127.5]
3	sugars_100g	[-27.5, 48.5]
4	fiber_100g	[-4.5, 7.5]
5	proteins_100g	[-11.5, 24.5]
6	salt_100g	[-1.5, 2.5]
7	sodium_100g	[0.0, 0.0]

valeurs négatives

sels et fibres 43,50 g 39,10 g → 40 g

sodium 16 g (40/2.5)

Energie (KJoules)



Outliers sous le seuil défini précéd



Les valeurs aberrantes seront remplacées par des valeurs nulles.

Nettoyage - imputation des valeurs manquantes

% de valeurs manquantes

carbohydrates_100g	30.804533
fat_100g	30.707576
fiber_100g	25.907093
energy_100g	0.521417
sodium_100g	0.361975
salt_100g	0.361975
sugars_100g	0.148668
saturated-fat_100g	0.144359
proteins_100g	0.142205
nutrition-score-fr_100g	0.000000
product_name	0.000000
nutrition_grade_fr	0.000000

KNN Imputer




% de valeurs


nutrition-score-fr_100g
sodium_100g
salt_100g
proteins_100g
fiber_100g
sugars_100g
carbohydrates_100g
saturated-fat_100g
fat_100g
energy_100g
product_name
nutrition_grade_fr

Nettoyage - imputation des valeurs manquantes

Avant imputation



Après imputation



Nettoyage - synthèse

46412 produits

12 colonnes

Nom du produit

Le score / grade

Les informations
nutritionnelles

product_name

nutrition_grade_fr
nutrition-score-fr_100g

sodium_100g
salt_100g
proteins_100g
fiber_100g
sugars_100g
carbohydrates_100g
saturated-fat_100g
fat_100g
energy_100g

Analyse exploratoire

- Distributions
- Analyse multivariée
- Hypothèses
- Anova
- ACP



Conclusion

- Jeu de données
- Nettoyage
- Nutriscore
- Evolution



Merci

- Questions ?

