




Construisez un modèle de scoring



Sommaire

- Contexte – problématique – données
- Modélisation
- Evaluation
- Importance des variables
- Conclusion

Le contexte



Société financière




Chargé de clientèle
Crédits à la consommation




Client
Score

Le projet



Classification supervisée

Données




Prédictions

La problématique métier

Limitier les faux négatifs :


Erreur de prédiction coûteuse
Ne pas prédire 0 au lieu de 1



Classes déséquilibrées :

Performance élevée $\leftrightarrow$ modèle satisfaisant
→ métrique adaptée

Les données






Transformation des données

- Outliers
- Valeurs manquantes
- Encodage des variables catégoriques
- Normalisation des variables numériques
- Nouvelles variables


Modélisation




Modélisation – les algorithmes

1 - Régression logistique

Modèle logistique appliqué à des données simulées




2 - Support Vector Machine




Modélisation – les algorithmes


3 – Random Forest



Tally: Six 1s and Three 0s
Prediction: 1



Modélisation - métrique



Sensibilité = $VP / \text{Positifs}$

Spécificité = $FP / \text{Négatifs}$

Métrique : Roc Auc

Modélisation – comparaison de modèles

classifieur	iteration1	iteration2	iteration3	iteration4	iteration5	iteration6
LogisticRegression	0.651050	0.735645	0.735645	0.731619	0.724593	0.717017
RandomForestClassifier	0.729515	0.728854	0.728978	0.715114	0.721146	0.723150
SVM	0.608164	0.735238	0.735238	0.735001	0.730251	0.731208

Modèle de référence : LogisticRegression : itération 1 : score auc : 0,64

Itération 1 : Imputer – comparaison avec les autres algorithmes

Itération 2 : Normalisation des données


Itération 3 : Stratified cross validation

Itération 4 : class weight : balanced

Itération 5 : Resampling data

Itération 6 : Nouvelles variables

Modélisation



Modélisation – comparaison de modèles

classifieur	iteration1	iteration2	iteration3	iteration4	iteration5	iteration6
LogisticRegression	0.651050	0.735645	0.735645	0.731619	0.724593	0.717017
RandomForestClassifier	0.729515	0.728854	0.728978	0.715114	0.721146	0.723150
SVM	0.608164	0.735238	0.735238	0.735001	0.730251	0.731208

Modèle de référence : LogisticRegression : itération 1 : score auc : 0,64

Itération 1 : Imputer – comparaison avec les autres algorithmes

Itération 2 : Normalisation des données



Itération 3 : Stratified cross validation

Itération 4 : class weight : balanced


Itération 5 : Resampling data

Itération 6 : Nouvelles variables


Evaluation




Evaluation



Seuil : 0,49



Importance des variables





Conclusion

- Modèle de classification supervisée : roc auc : 0,73.
- Améliorations :
 - Feature engineering
 - Feature Selection
 - Autres algorithmes (LightGBM...)