

Détectez les Bad Buzz grâce au Deep Learning



Air Paradis



Sommaire

- Contexte
- Données
- Approche 1 : API sur étagère
- Approche 2 : Modèle sur mesure simple
- Approche 3 : Modèle sur mesure avancé
- Récapitulatif
- Déploiement
- Conclusion



Air paradis

- ➔ Bad buzz
- ➔ Sentiments des tweets
- ➔ Comparaison de 3 approches



Dataset : Sentiment 140

- ➔ 1600000 tweets
- ➔ Label sentiment POSITIF / NEGATIF
- ➔ Equilibre des labels
- ➔ Accuracy



Preprocessing

Caractères spéciaux, majuscules, stop words

Stematisation, Lemmatisation

text	text_clean	text_clean_stem	text_clean_lem
glad i get out of babysitting!! but now i hav...	glad get babysitting clean house	glad get babysit clean hous	glad get babysitting clean house
Federer wants it bad. kickin some ass @ the Fr...	federer wants bad kickin ass french open oh mi...	feder want bad kickin ass french open oh miss ...	federer want bad kickin as french open oh miss...
@LegitLenaa miss you too babycakes.	miss babycakes	miss babycak	miss babycakes
#haveyouever tried mixing in peanut butter int...	haveyouever tried mixing peanut butter chocola...	haveyouev tri mix peanut butter chocol milk do...	haveyouever try mix peanut butter chocolate mi...
packing to go home for summer!	packing go home summer	pack go home summer	pack go home summer
omgomgomg. New internet possibly soon	omgomgomg new internet possibly soon	omgomgomg new internet possibl soon	omgomgomg new internet possibly soon



Approche 1 : API sur étagère

Azure cognitive services for languages

API

Verbe HTTP	POST
URI	Endpoint + chemin /text/analytics/version/ sentiment
En-tête	Ocp-Apim-Subscription-Key Content-Type
Corps	Tableau JSON documents[{Id text}...]




Approche 1 : API sur étagère


- Réponse : Id Sentiment Scores
- Scores : Positif / Négatif / Neutre / Mixed
- **Résultats**

	preprocess_type	accuracy	azure_sentiment_time
0	without_clean	0.742500	57.320783
1	clean_only	0.719045	61.546694
2	stem	0.675676	61.563812
3	lem	0.702074	60.604272

Approche 2 : Modèle sur mesure simple



Approche 2 : Modèle sur mesure simple





Approche 2 : Modèle sur mesure simple

Résultats

Properties

Status
✔ Completed

Created
Jan 28, 2022 2:38 PM

Started
Jan 28, 2022 2:38 PM

Duration
2m 29.84s

Compute duration
2m 29.84s

Tags

ⓘ No tags

Metrics

AUC 0.592	F1 Score 0.553
Accuracy 0.537	Lift curve Type: Table
Confusion matrix Type: Table	☰ View all metrics

Approche 3 : Modèle sur mesure avancé


Baseline : Naive Bayes

Modèle sur mesure :

Réseau de neurones classique


Réseau de neurones à mémoire : LSTM

BERT : Réseau de neurones pré-entraîné : BERT



Approche 3 : Modèle sur mesure avancé

Plongement de mots



Keras Inline

Word2Vec

GloVe




Approche 3 : Modèle sur mesure avancé

Mode opératoire


- 1 Basic / LSTM → LSTM
- 2 clean only / stem / lem → LSTM lem
- 3 embedding inline / Word2Vec / GloVe → LSTM lem GloVe
- 4 Optimisation

Approche 3 : Modèle sur mesure avancé

Optimisation : Dropout



a) Standard Neural Net



b) After dropout



Approche 3 : Modèle sur mesure avancé


Résultats

	model	preprocess	embedding	dropout	epochs	sample	accuracy	fit_time	eval_time
0	Naive Bayes	clean_only				20000	71.60	1.93	0.13
1	basic	clean_only	inline		8	20000	69.65	6.02	2.22
2	lstm	clean_only	inline	0.2	3	20000	71.60	112.66	3.20
3	lstm	stem	inline	0.2	5	20000	71.05	203.31	3.41
4	lstm	lem	inline	0.2	4	20000	71.20	163.96	3.58
5	lstm	lem	w2vec	0.2	5	20000	72.10	265.82	5.74
6	lstm	lem	glove	0.2	5	20000	72.25	81.98	1.58
7	lstm	lem	glove	0.5	5	20000	71.95	80.56	1.40
8	lstm	lem	glove	0.5	12	20000	72.65	206.67	1.62
9	bert	lem			5	1000	64.00	613.69	10.77



Synthèse des 3 approches

	Temps de Développement	Temps D'entraînement	Durée Prédictions	Tuning	Performances
API sur étagère	++	+	-	-	-
Modèle simple	+	+	+	+	-
Modèle avancé	-	-	+	++	++



Démo ...



Conclusion

- ➔ Avantages et inconvénients pour chaque approche
- ➔ Utilisation / Contexte / Compromis
- ➔ Temps, Coûts, Performances